

数字人网页导航助手 (Web-Agent)

技术实现方案及架构白皮书 - 教育数字人大赛参赛参考

1. 项目愿景与目标

本项目旨在开发一个实时交互的 3D 数字人助手，以浏览器插件形式存在，帮助用户在访问陌生或复杂网站时，通过语音交互获取即时导航指引。核心追求：**低延迟响应**、**高精度理解**、**沉浸式陪伴**。

2. 核心技术栈 (Technical Stack)

维度	技术实现	关键特性
感知层	DOM Parser + Chrome Extension API	实时提取交互元素 JSON，轻量化数据传输。
展现层	Three.js + @pixiv/three-vrm	WebGL 端侧渲染，3D 数字人 VRM 驱动，口型同步。
对话层	Web Speech API (ASR) + Streaming TTS	流式语音输入输出，降低用户感知的等待时间。
大脑层	8B LLM (Llama 3 / Qwen 2.5)	GGUF 4-bit 量化，部署于本地 Ollama 或云端 API。

3. 核心功能场景实现逻辑

场景 A：基础高亮引导

用户提问 -> 后端分析 DOM -> 返回目标选择器 (#id/.class) -> 插件执行 CSS 高亮动画。

场景 B：多步逻辑引导 (Task Queue)

实现机制：状态机任务队列

后端返回一个任务数组，插件作为执行器。使用 MutationObserver 监听网页 DOM 变化，自动触发后续步骤。

```
// 任务结构示例
[
  {
    "step": 1,
    "speech": "请先点击头像",
    "target": "#avatar",
    "trigger": "click"
  },
  {
    "step": 2,
    "speech": "现在点击设置",
    "target": ".settings",
    "trigger": "visible"
  }
]
```

场景 C：全本地运行 (Privacy & Performance)

利用 Mac M4 芯片的统一内存架构，通过 Ollama 部署量化模型。8B 模型在 4-bit 量化下约占 5-6GB 内存，配合轻量化 TTS 实现完全断网交互。

4. 8B 模型可行性评估 (针对 M4 16GB)

- 内存分配：** 系统(4G) + 模型(6G) + 浏览器及渲染(4G) + 冗余(2G) = 16G。
- 推理速度：** M4 芯片预计可达 20-40 tokens/s，远超语音播报速度，确保交互无卡顿。
- 智力表现：** 8B 模型在结构化指令 (JSON 输出) 和特定领域逻辑推理方面表现稳定。

5. 核心代码模块指引 (给 Claude 的 Prompt 参考)

在请 Claude 辅助编写代码时，建议按以下模块进行：

- 模块 1：DOM 提取器。** 编写脚本过滤网页无用信息，仅提取 button 和 a 标签的 ID、文本和坐标。

2. **模块 2：VRM 控制器。** 使用 Three.js 加载模型，并实现基于音频音量的简单唇形同步逻辑。
3. **模块 3：任务执行引擎。** 实现 MutationObserver 逻辑，监听用户点击并触发下一条语音指引。

项目主体：数字人网页导航助手 | 运行环境：MacBook M4 16G | 目标：教育数字人大赛作品