

数字人网页导航助手 (Web-Agent)

技术实现方案及架构白皮书 v2.0 — 教育数字人大赛参赛参考

一、项目愿景与目标

本项目旨在开发一个实时交互的 3D 数字人助手，以 Chrome 浏览器扩展形式存在，帮助用户在访问陌生或复杂网站时，通过语音交互获取即时导航指引。

核心追求：低延迟响应（端到端 < 3s）、高精度理解、沉浸式陪伴。

v2.0 优化方向：将核心推理能力迁移至云端 API（DeepSeek），本地聚焦 DOM 预处理和执行可靠性，3D 数字人做轻量化陪伴。

二、架构总览 — 五层架构



关键变化：

- 新增预处理层，解决 LLM 上下文爆炸和选择器幻觉问题
- 大脑层从本地 8B 量化模型 → 云端 DeepSeek API
- 展现层从 VRM 实时驱动 → GLB 模型 + 状态切换动画
- 新增编排层，提供多级降级和重试保障

三、核心技术栈

维度	技术实现	关键特性
感知层	DOM Parser + Chrome Extension API	实时提取可交互元素，50ms 内完成蒸馏
预处理层	DOM Distiller (自研JS模块)	过滤→去重→聚类→语义摘要→选择器增强
大脑层	DeepSeek Chat / DeepSeek V4 Flash	云端 API，JSON 结构化指令输出
编排层	State Machine + Task Queue	5级选择器降级，MutationObserver 驱动
对话层	Web Speech API + Edge TTS	流式语音输入输出，免费 TTS
展现层	Three.js + GLB (Ready Player Me)	Side Panel 独立渲染，状态切换动画
通信	Chrome Runtime Messages	Content Script ↔ Background SW ↔ Side Panel

四、模型选型

方案	模型	延迟	成本	适用场景
首选	DeepSeek Chat (V3)	1-2s	极低	主力推理，JSON指令输出能力强，中文理解好
备选	DeepSeek V4 Flash	0.5-1s	极低	更快推理，低延迟场景，已正式发布
兜底	本地 8B 量化模型 (Ollama)	3-5s	免费	断网场景，隐私敏感场景

建议：默认使用 DeepSeek Chat 或 V4 Flash，两种模型均可在代码中一键切换。本地模式仅作降级方案保留接口。

五、核心功能场景

场景 A：基础高亮引导

用户提问 → 蒸馏DOM → 拼装Prompt → DeepSeek API → 解析JSON指令 → Content Script执行CSS高亮动画

- 高亮动画：CSS outline + 脉冲波纹效果 (pulse-ripple)
- 语音播报：Edge TTS 流式合成，首字延迟 < 200ms
- 目标元素定位：使用 JSON 中的 selector 精确选中

场景 B：多步逻辑引导 (Task Queue)

状态机任务队列机制：

- 后端返回任务数组，插件作为执行器
- MutationObserver 监听 DOM 变化，自动触发后续步骤
- 支持 trigger 类型：click / visible / input / navigate

```
[
  {
    "step": 1,
    "speech": "请先点击头像",
    "target": "#avatar",
    "trigger": "click",
  },
  {
    "step": 2,
    "speech": "现在点击设置",
    "target": ".settings",
    "trigger": "visible",
  },
  {
    "step": 3,
    "speech": "在输入框中输入您的姓名",
    "target": "#name-input",
    "trigger": "input"
  }
]
```

场景 C：降级兜底 (5级选择器策略)

Level 1: 精确选择器 → document.querySelector("#login-btn")
Level 2: 弱化选择器 → document.querySelector(".btn-primary")
Level 3: XPath文本匹配 → //button[contains(text(),"登录")]
Level 4: LLM重试 → 带失败上下文重新请求API
Level 5: 语音降级 → 口头指引用户，不执行自动化操作

六、预处理层：DOM蒸馏管线

这是整个系统最重要的优化 — 将 5000 token 的原始 DOM 压缩至 500 token 的语义摘要。

蒸馏流程




蒸馏前后对比

指标	蒸馏前	蒸馏后
Token 数	3000-5000	300-500
有效信息密度	~15%	~90%
LLM 指令遵循率	~60%	~90%
处理耗时	0ms (无处理)	< 50ms (本地JS)

七、编排层：可靠性保障

状态机设计



选择器降级引擎

```
execute(target, action):  
  |— Level 1: querySelector(target)           → 精确匹配, 90%+命中  
  |— Level 2: weakenSelector(target)          → 弱化nth-child, 仅用class  
  |— Level 3: xpathByText(target)             → 文本内容XPath匹配  
  |— Level 4: retryWithLLM(target, reason)    → 带失败信息重新推理  
  |— Level 5: fallbackVerbal(target)          → 语音指引, 不自动操作
```

MutationObserver 任务驱动

- 监听目标元素的 DOM 变化 (appear/disappear/attribute change)
- 自动触发任务队列的下一步
- 超时机制: 30秒未匹配自动降级

八、延迟预算 — 端到端 < 3秒

环节	耗时	优化手段
ASR 语音识别	300-500ms	Web Speech API 流式实时出字
DOM 蒸馏	< 50ms	纯前端本地执行，无网络开销
API 请求 + LLM 推理	500-1500ms	DeepSeek V4 Flash 或 Chat, streaming模式
指令解析	< 10ms	JSON.parse
高亮/点击执行	< 50ms	原生DOM操作
TTS 语音合成	200-500ms	Edge TTS streaming, 首段200ms可播放
合计	≈ 1.1-2.6s	感知延迟可接受

关键优化：所有环节使用 streaming，不等待完整结果。LLM 出第一个 token 即开始解析。TTS 出第一段音频即开始播放。

九、3D 数字人方案

原方案 vs 优化方案


对比项	原方案	优化方案
模型格式	VRM (10MB+)	GLB (Ready Player Me, < 5MB)
驱动方式	实时音频分析唇形同步	4套预设动画按状态切换
渲染位置	Content Script注入	Chrome Side Panel独立渲染
GPU占用	~2GB	~500MB
动画状态	idle / talking / thinking / success	同左，预录循环播放
实现复杂度	高（需音频分析+blendshape映射）	中（状态机+动画播放）

四种动画状态

状态	触发条件	动画描述
idle	等待用户输入	自然呼吸/微动，眼神随机移动
listening	用户正在说话	点头/偏头倾听姿态
thinking	等待LLM返回结果	思考姿态，轻微皱眉
speaking	TTS正在播报	嘴部张合循环，配合手势

十、Chrome Extension 进程架构

Message Passing 通信协议



关键消息类型:

- ASR_RESULT — Side Panel → Background: 用户语音转文本
- DOM_QUERY — Background → Content Script: 请求蒸馏DOM
- DOM_RESULT — Content Script → Background: 蒸馏后的页面摘要
- LLM_INSTRUCTION — Background → Content Script: 执行指令
- EXEC_RESULT — Content Script → Background: 执行结果
- TTS_SPEAK — Background → Side Panel: 触发语音播报
- ANIM_STATE — Background → Side Panel: 切换数字人动画状态

十一、开发优先级

Phase 1 — 核心链路（必须完成，约10天）

- DOM蒸馏管线 (dom-distiller.js)
- DeepSeek API 客户端 (llm-client.js)
- Content Script (DOM提取 + 高亮动画 + content.css)
- Background Service Worker (编排 + 消息路由)
- Edge TTS 模块 (tts.js)
- Web Speech API 语音输入
- Extension Manifest 配置

Phase 2 — 增强体验（加分项，约5天）

- 选择器5级降级引擎 (selector-engine.js)
- 任务队列 + MutationObserver (task-queue.js)
- Side Panel 3D数字人 (Three.js + GLB)

Phase 3 — 锦上添花（有余力做）

- 操作确认/撤销
- 操作历史回溯
- DeepSeek V4 Flash / Chat 切换开关
- 本地 Ollama 降级接口

十二、竞品对比

特性	本项目	Microsoft Copilot	传统网页导航
3D数字人陪伴	✔	✘	✘
语音交互	✔ 全语音	✔ 文本为主	✘
多步任务自动化	✔	⚠ 有限	✘
选择器降级策略	✔ 5级	✘ 无	N/A
离线运行	⚠ 计划中	✘	N/A
隐私保护	✔ 本地蒸馏	⚠ 上传全DOM	✔
中文网站适配	✔ 针对优化	⚠ 一般	✘

项目主体：数字人网页导航助手 | 运行环境：MacBook M4 16G (开发) + 全平台 (部署) | 目标：教育数字人大赛作品 | 版本：v2.0