

智引灵 AI 导航导师

技术实现方案及架构白皮书 v3.0

第三届"教育数字人大赛——我和数字人的故事"参赛作品

一、项目概述

1.1 项目愿景

"智引灵"是一个以 Chrome 浏览器扩展形态运行的 AI 数字人导航导师，专为高校师生设计。用户在面对教务系统、在线课程平台、学术资源站点等教育类网站时，通过**语音对话**即可获得即时的页面导航指引——数字人会高亮目标元素、语音播报操作提示，帮助学生和教师快速找到所需功能。

1.2 核心目标

目标	指标
低延迟响应	端到端 < 3秒 (ASR + DOM蒸馏 + LLM推理 + 执行 + TTS)
高精度定位	目标元素匹配率 > 90% (精确 + 弱化 + XPath三级)
沉浸式陪伴	双形态数字人 (侧边栏主形象 + 页面浮窗 Widget)
可靠降级	5级选择器策略，确保在最坏情况下仍有语音指引

1.3 v3.0 更新要点

- 教育身份注入**：LLM System Prompt 从通用导航助手升级为"智引灵"虚拟助教角色
- 意图感知蒸馏**：DOM蒸馏支持根据用户意图智能聚焦页面区域（如"登录"→优先扫描导航栏）
- 双录音路径**：Offscreen Document + Content Script 双通道，兼容侧边栏关闭场景
- 高亮验证机制**：LLM 输出 verifyText，前端校验高亮元素是否匹配，防止选错目标
- 双模推理**：全量 Prompt → 极简 Prompt 自动降级，应对 API 安全过滤或 token 超限
- SPA 路由感知**：MutationObserver 检测 SPA 页面切换，自动失效 DOM 缓存

二、系统架构

2.1 六层架构总览

展现层	Side Panel (SVG 数字人 + 动画) Content Widget (皮卡丘浮窗 + 扇出菜单)
对话层	Offscreen Document (getUserMedia 录音) Content Script (备选录音路径) Chrome TTS (语音合成播报)
编排层	Service Worker (状态机 + 消息路由) TaskQueue (多步操作 + MutationObserver) SelectorEngine (5级选择器降级)
大脑层	DeepSeek Chat / DeepSeek V4 Flash infer() 全量推理 + inferMinimal() 极简 recoverPartialJson() 截断抢救
预处理层	DomDistiller (意图驱动蒸馏管线) 过滤→去重→意图聚类→摘要→选择器→Prompt
感知层	Content Script DOM Parser 可交互元素提取 + SPA路由变化检测

2.2 进程与通信

Chrome Extension MV3 架构下，系统由四个独立进程组成，通过 Chrome Runtime Messages 通信：

进程	文件	职责
Side Panel	sidepanel/sidepanel.html + sidepanel.js	SVG数字人渲染、设置面板、文字输入 备用通道
Background SW	background/service-worker.js	状态持有者、消息路由、API编排、TTS 播报
Content Script	content/content.js	DOM操作、Widget渲染、高亮动画、 任务执行、备选录音
Offscreen Doc	offscreen/offscreen.html + offscreen.js	getUserMedia 麦克风录音

关键消息类型：

消息	方向	用途
CTRL_START_REC / CTRL_STOP_REC	SidePanel → SW → Content	录音启停控制
RECORDING_DONE	Content/ Offscreen → SW	录音完成，携带 base64 音频
RECORDING_ERROR	Content/ Offscreen → SW	录音失败（权限/设备）
DOM_PRECOLLECT	SW → Content	触发DOM预收集（与录音并行）
DOM_DISTILL	SW → Content	蒸馏DOM，携带用户意图
EXEC_HIGHLIGHT / EXEC_CLICK / EXEC_INPUT / EXEC_SCROLL	SW → Content	执行导航指令
EXEC_TASK_QUEUE	SW → Content	执行多步任务队列
EXEC_VERIFY_HIGHLIGHT	SW → Content	高亮后验证文字匹配
ANIM_SET_STATE	SW → SidePanel + Content	同步动画状态
TTS_SPEAK	SW → SidePanel	TTS播报（备用路径，已改用chrome.tts）
STATUS_TEXT	SW → SidePanel + Content	推送状态文本
PAGE_CHANGED	Content → SW	SPA路由变化通知

三、核心技术详解

3.1 DOM蒸馏管线（DomDistiller）

这是整个系统最关键的优化——将 3000–5000 token 的原始 DOM 压缩至 300–500 token 的语义摘要，同时保证 LLM 指令遵循率 > 90%。

六阶段管线：

原始DOM (2000+标签)

|

▼

- ① 过滤 - `querySelectorAll` 捕获所有可交互元素
 (button, a[href], input, select, textarea,
 [role="button"], [role="link"], [onclick], [tabindex])
 上限 500 个, 防止超大页面卡死

|

▼

- ② 去重 - 按"标签名 + 可见文本"去重, id 唯一元素保留

|

▼

- ③ 意图感知聚类 - 根据用户意图智能分配各区域的采集配额:
- 命中意图区域: 24 个元素 (2倍宽限)
 - 非相关区域 (有意图时): 4 个元素 (严格限制)
 - 无意图时: 12 个元素 (均匀分布)

区域划分策略:

- ARIA landmark (role="banner"/"navigation"/"main"...)
- 语义标签 (header/nav/main/aside/footer)
- 视口位置推断 (topRatio<0.15→header-bar, >0.85→footer)

|

▼

- ④ 语义摘要 - 每个区域生成自然语言描述
 "★ 顶部区域: [登录] [注册] [我的账户]"
 "导航栏: [首页] [课程中心] [成绩查询] [个人设置]"

|

▼

- ⑤ 选择器增强 - 每个元素生成三层选择器:
- weakSelector: `button.btn-primary`
 - strongSelector: `button.btn-primary[data-testid="submit-btn"]`
 - textFallback: `//button[contains(text(),"提交")]`

|

▼

- ⑥ Prompt 拼装 - 页面标题 + meta描述 + h1-h3 + 区域摘要 + 元素列表 + 用户意图
 有意图时 60 个元素, 无意图时 35 个元素

意图模式匹配 (10个预设 + 泛化兜底):

用户说	优先采集区域
"登录/注册/账号"	header-bar, navigation, banner
"搜索/查找"	search, header-bar, navigation
"设置/配置/个人资料"	sidebar, navigation, complementary
"提交/确认/保存/下一步"	form, main-content
"导航/菜单/侧边栏"	navigation, sidebar, header-bar
"购买/支付/下单"	main-content, sidebar
"上传/导入/文件"	main-content, form
"关闭/退出/返回"	header-bar, main-content
"介绍/说明/这是什么页面"	无优先（均匀采集，LLM综合）

预收集缓存机制： 用户按下麦克风的瞬间，content script 同步执行 `DOM_PRECOLLECT`，与录音并行完成元素采集。ASR 完成后，`DOM_DISTILL` 直接使用缓存（TTL 30秒，URL 校验），省去重复扫描 ~80-150ms。

3.2 LLM 推理引擎 (llm-client.js)

双模型支持：

模型	API ID	延迟	适用场景
DeepSeek Chat (V3)	deepseek-chat	1-2s	主力推理，JSON指令能力强
DeepSeek V4 Flash	deepseek-v4-flash	0.5-1s	更快推理，低延迟场景

双模推理策略：

```
infer(fullPrompt, intent, apiKey, model)
├── 正常返回 → 解析 JSON → 返回指令
└── API_EMPTY_RESPONSE (安全过滤/token超限)
    └── 自动触发 inferMinimal()
        ├── 去掉所有选择器细节
        ├── 仅保留区域摘要 + 用户意图
        ├── max_tokens = 200
        └── 只要求 speech + verifyText
```

JSON 截断抢救 (recoverPartialJson) : LLM 响应被 `max_tokens` 截断时 (`{"target": "...", "action": "highlig..."}`) , 通过正则逐字段抢救已完成的 JSON 字段 (target / fallbackText / action / speech / value) , 避免因截断导致整个推理结果作废。

3.3 语音交互流水线

双录音路径:


路径	上下文	优点	缺点
Offscreen Document	独立隐藏页面	不受侧边栏关闭影响	创建offscreen有开销
Content Script	页面内	响应快, 直接访问页面	依赖侧边栏保持打开

两路径互为备份: Side Panel 按下麦克风 → Offscreen 启动; Widget 按下麦克风 → Content Script 直接录音。

ASR 配置: - 端点: SiliconFlow Whisper API (`api.siliconflow.cn`) - 模型: `FunAudioLLM/SenseVoiceSmall` - 语言: 中文 - 格式: WebM (Opus codec) - 超时: 10 秒

TTS 配置: - 引擎: Chrome `chrome.tts` API (内置引擎, 无需 API Key) - 语言: zh-CN - 语速: 0.91, 音高: 1.1, 音量: 0.9 - 优势: 从 Service Worker 直接发声, 不依赖侧边栏聚焦状态

四种动画状态同步:



每种状态对应 Side Panel SVG 动画和 Widget SVG 动画同步切换, 光晕颜色不同 (listening 橙色 / thinking 紫色 / speaking 绿色 / idle 粉色) 。

3.4 选择器降级引擎 (SelectorEngine)

5级降级策略, 确保在任何情况下都能给出反馈:

级别	方法	说明	典型命中率
L1 精确匹配	<code>document.querySelector(selector)</code>	LLM 输出的 strongSelector 直接命中	~90%
L2 弱化匹配	去掉属性和 id，仅用 tag + class；多匹配时用 fallbackText 文本筛选	页面 class 稳定即可命中	~7%
L3 XPath文本	<code>//tag[contains(text(),"...")]</code>	根据元素可见文本定位	~2%
L3b 广域文本	对所有可交互元素做全量文本比对	L3 标签名不匹配时兜底	~0.5%
L4 LLM重试	带失败上下文重新请求 API	元素确实不存在时	—
L5 语音降级	口头指引用户自己操作	最终兜底	~0.5%

3.5 高亮验证机制

解决"LLM 说用量统计但高亮了模型广场"的语义错配问题：

```
EXEC_HIGHLIGHT(target=".nav-item-3", fallbackText="用量统计")
├─ ① 正常高亮目标元素，同时记录 highlightTargetEl
├─ ② EXEC_VERIFY_HIGHLIGHT(verifyText="用量统计")
│   ├── 被高亮元素文字包含"用量统计" → verified: true ✓
│   └── 文字不匹配 → 全页搜索可交互元素
│       ├── 找到文字包含"用量统计"的元素 → 重新高亮 ✦
│       └── 未找到 → verified: false，不操作
```

3.6 多步任务队列（TaskQueue）

状态机驱动，支持三种触发器：

触发器	行为	等待机制
click	直接点击元素	无等待
visible	等待元素出现后点击	MutationObserver 监听 DOM 变化 + 200ms 定时轮询, 30s 超时
input	等待元素出现后填入内容	同 visible

React/Vue/Angular 兼容： 通过 `Object.getOwnPropertyDescriptor(HTMLInputElement.prototype, 'value')` 劫持 setter，确保框架能感知 value 变化并触发响应式更新。

3.7 双形态数字人

侧边栏主形象 (Side Panel)： – 纯 SVG 渲染，不依赖 Three.js/WebGL – 粉白色调、天蓝眼、轨道环光晕 – 4 种动画状态：浮动(idle) / 点头(listening) / 倾斜摇摆(thinking) / 张嘴跳动(speaking) – 每种状态光晕颜色不同

页面浮窗 Widget (Content Script)： – Shadow DOM 完全隔离，CSS 不污染宿主页面 – 支持拖拽移动，位置持久化到 chrome.storage – 扇出菜单（语音/文字/设置）从角色腹部展开 – 文字输入框深色半透明风格 – 点击外部自动收起菜单

四、端到端延迟预算

环节	耗时	优化手段
DOM 预收集	< 50ms	纯前端本地执行，与录音并行
录音 + ASR	300–500ms	边录边传，SenseVoiceSmall 小模型
DOM 蒸馏	< 50ms	预收集缓存复用，跳过重复扫描
API 请求 + LLM 推理	500–1500ms	DeepSeek V4 Flash 优先, 15s 超时
JSON 解析	< 10ms	JSON.parse, 截断时正则抢救
高亮/点击执行	< 50ms	原生 DOM 操作, behavior:instant
TTS 语音合成	200–500ms	chrome.tts 引擎, 首段 200ms 可播放

合计： 约 1.1 – 2.6 秒（最优路径），感知延迟可接受。

五、代码规模与模块清单

模块	文件	行数	职责
编排中枢	background/service-worker.js	512	状态管理、消息路由、API编排、TTS
页面执行器	content/content.js	856	Widget渲染、录音、高亮、气泡、SPA检测
侧边栏UI	sidepanel/sidepanel.js	218	动画控制、录音按钮、设置面板、文字输入
后台录音	offscreen/offscreen.js	87	独立document的getUserMedia
DOM蒸馏	lib/dom-distiller.js	405	过滤去重聚类摘要选择器Prompt全管线
LLM客户端	lib/llm-client.js	239	推理+极简重试+JSON抢救+流式
ASR客户端	lib/asr-client.js	79	Whisper ASR (SiliconFlow)
选择器引擎	lib/selector-engine.js	208	5级降级+广域文本搜索
任务队列	lib/task-queue.js	263	多步状态机+气泡+React兼容输入
页面样式	content/content.css	123	高亮/波纹/气泡/箭头动画
扩展配置	manifest.json	51	MV3权限与入口声明
合计	11 个文件	~3041	

六、安全与隐私设计

维度	措施
DOM 数据	仅提取可交互元素文本，不传输原始页面内容；蒸馏在本地完成
API Key	加密存储于 chrome.storage.local，由用户自主填入；demo 默认 key 仅为开发测试用
语音数据	录音仅在本地浏览器内完成 base64 编码，通过 HTTPS 传输至 ASR 服务
内容安全	扩展仅请求必要权限（sidePanel/storage/activeTab/scripting/tts）
用户隐私	不收集用户身份信息，不存储浏览历史，不上报使用数据
开源许可	计划赛后开源，便于教育机构审计和二次开发

七、竞品对比

特性	智引灵	Microsoft Copilot	传统网页导航
数字人形象陪伴	✓ 双形态SVG	✗	✗
全语音交互	✓	文本为主	✗
意图感知 DOM 蒸馏	✓（10+意图模式）	✗（上传全DOM）	N/A
多步任务自动化	✓ 状态机	有限	✗
5级选择器降级	✓	✗	N/A
高亮验证机制	✓（verifyText）	✗	N/A
双模推理降级	✓（全量→极简）	✗	N/A
JSON 截断抢救	✓	✗	N/A
离线运行	计划中（Ollama 8B）	✗	N/A
隐私保护	本地蒸馏	上传全DOM	✓（纯本地）
中文教育场景适配	✓ 针对优化	一般	✓
平台	Chrome 扩展（全平台）	Edge 集成	浏览器原生

八、开发环境与部署

项目	说明
开发环境	macOS + Chrome 120+
运行环境	Chrome 浏览器（全平台：Mac/Windows/Linux）
外部依赖	DeepSeek API（LLM） + SiliconFlow API（ASR）
扩展类型	Chrome Extension Manifest V3
安装方式	开发者模式加载已解压的扩展目录 / Chrome Web Store 发布

九、后续规划

阶段	内容
Phase 2	本地 Ollama 8B 离线降级、移动端适配
Phase 3	操作确认/撤销、历史回溯、多语言（先英后日韩）
远期	教育领域知识库 RAG、多平台扩展（Firefox/Safari）、无障碍（WCAG）合规

项目：智引灵 AI 导航导师 | 版本：v3.0 | 2026年5月